


Voice on the FPGA

— Streaming Speech on the Edge —



VOICE EDGE AI, 2026

1.1 Trực Giác: Sự Khác Biệt Cốt Lõi Giữa Thị Giác Máy Tính và AI Giọng Nói Biên

► MỤC TIÊU HỌC TẬP

Thay vì xem xử lý âm thanh như một chuỗi ma trận số học trong hộp đen, mục này dẫn dắt bạn đi qua cơ chế vật lý và cơ học của sóng âm. Chúng ta sẽ suy diễn vì sao xử lý giọng nói phân kỳ căn bản so với thị giác máy tính, lý do độ trễ biến bắt buộc kích thước lô thực thi phải bằng một ($batch = 1$), và cách quán tính sinh học của các cơ quan phát âm định hình ranh giới khung thời gian thực cho mọi kiến trúc silicon được phát triển trong cuốn sách này.


Bức Ảnh Trong Phòng Trưng Bày và Màng Rung Của Micro

Một bức ảnh là một thực thể đã hoàn thành. Một âm thanh là một quá trình vật lý chưa kết thúc.

Sự phân biệt duy nhất này chi phối gần như mọi đánh đổi kiến trúc trong toàn bộ cuốn sách. Trong thị giác máy tính, một bức ảnh số truyền đến bộ xử lý dưới dạng một ma trận không gian nguyên vẹn, có giới hạn rõ ràng. Các điểm ảnh ở mép dưới tồn tại tại cùng một thời điểm chính xác như các điểm ảnh ở mép trên. Xử lý bức ảnh thứ hai không làm thay đổi thực tại không gian của bức ảnh thứ nhất; bạn có thể xếp chồng tám bức ảnh lại với nhau thành một lô duy nhất và đưa chúng đồng thời qua mạng nơ-ron.

Việc nhóm các đầu vào độc lập theo cách này được gọi là **gom lô** (batching), và số lượng mẫu được nhóm lại đại diện cho **kích thước lô** (B – batch size). Một bộ xử lý đồ họa (GPU)—được xây dựng từ hàng nghìn luồng thực thi số học nhẹ vận hành đồng bộ—thực hiện một phép nhân ma trận lớn hiệu quả hơn rất nhiều so với khi phải thực hiện tám phép nhân nhỏ rời rạc. Trên GPU máy tính để bàn hoặc đám mây, việc gom lô mang lại lợi thế thông lượng to lớn gần như miễn phí. Cái giá duy nhất phải đánh đổi là sự kiên nhẫn—và một bức ảnh tĩnh nằm yên trong bộ nhớ không hề có một thời hạn đếm ngược nào.

Tín hiệu giọng nói dạng dòng (streaming) mang một thực tại vật lý hoàn toàn trái ngược. Dữ liệu âm học không xuất hiện như một khung vẽ hai chiều hoàn chỉnh; nó truyền đến dưới dạng một dòng mẫu áp suất không khí liên tục được đo bởi màng rung dao động của micro. Để tập hợp một lô gồm tám khung âm thanh, hệ thống xử lý không thể tự tạo ra các mẫu tương lai từ hư không. Nó bị buộc về mặt vật lý phải giữ khung âm thanh đầu tiên nằm chờ trong hàng đợi cho đến khi khung thứ tám hoàn tất việc dao động qua không khí và đi qua bộ chuyển đổi tương tự – số.



Hình 1.1a: Sự phân kỳ vật lý và hình học giữa thị giác máy tính không gian và AI giọng nói biên dạng dòng cho thấy dữ liệu âm thanh diễn tiến tuần tự theo thời gian khiến việc gom lô bắt buộc phải trả giá bằng việc giữ khung âm thanh nằm chờ.

Độ trễ (τ)—khoảng thời gian vật lý trôi qua từ thời điểm sóng áp suất âm thanh chạm vào micro đến thời điểm bộ xử lý biên đưa ra quyết định ngôn ngữ khả thi—không phải là một chỉ số đo lường trừu tượng của phần mềm. Trong một hệ thống dòng tương tác, việc gom lô không bao giờ miễn phí: mỗi phần tử bổ sung vào lô đều được đánh đổi trực tiếp bằng sự hy sinh độ trễ của người dùng.

Hành Trình Suy Diễn: Thiết Lập Bài Toán Song Đề Gom Lô

Để hiểu vì sao kiến trúc giọng nói biên vận hành khác biệt so với các hệ thống thị giác, hãy xem xét hai giả thuyết đối lập mà một kỹ sư có thể đặt ra khi định cỡ bộ đệm đầu vào:

- **Giả thuyết A (Ngộ nhận thông lượng hàng loạt của GPU):** Việc gom lô được cho là mang lại giá tốc “miễn phí”. Trong môi trường máy chủ hoặc xử lý ảnh tĩnh, việc nhóm tám đầu vào không tốn thêm thời gian chờ đợi nào vì mọi dữ liệu đều đã được nạp sẵn vào bộ nhớ hệ thống. Dưới giả định này, một kỹ sư có thể kỳ vọng rằng việc gom tám khung âm thanh trên bộ xử lý biên sẽ cải thiện hiệu suất tính toán mà không phải trả giá.
- **Giả thuyết B (Thực tại vật lý dạng dòng):** Âm thanh không nằm chờ sẵn trong bộ nhớ; nó được tạo ra bởi một người nói bằng xương bằng thịt diễn tiến liên tục theo thời gian. Để xử lý một lô gồm tám khung, phần cứng phải tạm dừng về mặt vật lý và chờ người nói phát ra các sóng âm tương lai.

Lời giải đáp xuất hiện ngay lập tức: Giả thuyết A sụp đổ vì nó nhầm lẫn giữa dữ liệu tồn tại trong không gian với dữ liệu mở ra theo thời gian. Trong âm thanh dạng dòng, gom lô không phải là hiệu năng miễn phí—nó được đánh đổi trực tiếp bằng độ trễ τ .

Chúng ta có thể lượng hóa hình phạt vật lý này thành hai trạng thái cụ thể:

- **Trạng thái 1 — Hình phạt xếp hàng đầu vào:**

Giả sử tầng tiền xử lý âm học tạo ra một khung phân tích sau mỗi T_h giây, trong đó T_h đại diện cho **chu kỳ bước nhảy** (khoảng cách thời gian giữa hai cửa sổ phân tích liên tiếp). Nếu bộ máy suy diễn từ chối tính toán cho đến khi tập hợp đủ một lô gồm B khung, thì khung đầu tiên được thu nhận sẽ phải nằm chờ hoàn toàn vô công trong bộ nhớ trong khi các khung 2, 3, $\dots$, B đang được ghi lại:

$$\Delta t_{\text{wait}} = (B - 1) T_h$$

Trong công thức này, $(B - 1)$ đại diện cho số khoảng khung thời gian tiếp theo buộc phải trôi qua trong thế giới vật lý trước khi bộ đệm lô được tuyên bố là đã đầy.

- **Trạng thái 2 — Hình phạt độ trễ tại $B = 8$:**

Xuyên suốt cuốn sách này, quy trình xử lý tiếng nói biên tiêu chuẩn cố định chu kỳ bước nhảy tại $T_h = 10$ ms (một tốc độ mà nguồn gốc sinh học của nó sẽ được suy dẫn ngay bên dưới). Nếu một nhà thiết kế hệ thống cố gắng vận hành bộ tăng tốc biên ở kích thước lô khiêm tốn là $B = 8$ để tăng hiệu quả sử dụng các luồng số học:


$$\Delta t_{\text{wait}} = (8 - 1) \times 10 \text{ ms} = 70 \text{ ms}$$

Hãy chú ý điều gì đã diễn ra: **70 ms độ trễ thuần túy đã bị cộng thêm vào hệ thống trước khi một phép nhân đơn lẻ nào kịp bắt đầu.**

Hình phạt 70 ms này là hệ quả số học bất biến của chính sách gom lô, không phải là khuyết tật của chất lượng mã nguồn hay băng thông bus. Trong một bộ nhận dạng từ khóa thức tỉnh (Keyword Spotting – KWS) mang tính tương tác, 70 ms chính là ranh giới phân định giữa cảm giác tức thì và cảm giác giật cục, trì trệ.

Thuế gom lô: Độ trễ xếp hàng đầu vào cho $B = 8$ khung

Độ trễ chính sách (Khung 1 bị buộc chờ trước mọi phép toán MAC)



Hình 1.1b: Hình phạt độ trễ số học do chính sách gom lô áp đặt lên dòng âm thanh cho thấy Khung 1 buộc phải nằm chờ vô công $(B - 1)T_h = 70$ ms trong bộ đệm đầu vào hoàn toàn độc lập với xung nhịp xử lý hay thông lượng tính toán.

★ PHÁT HIỆN THEN CHỐT

Một giao diện giọng nói biên vận hành trước sự hiện diện vật lý của một người đang nói không thể tích lũy các đầu vào theo thời gian; để bảo toàn tính tương tác thời gian thực, hệ thống bị khóa chặt vào:

$$batch = 1$$

Câu hỏi thiết kế cốt lõi đối với kỹ sư kiến trúc phần cứng biên không phải là: “*Làm thế nào để tính toán một lô ma trận khổng lồ với thông lượng tối đa?*”

Mà là: “*Làm thế nào để thực thi MỘT khung đơn lẻ, gọn nhẹ đến khi hoàn tất trọn vẹn trong ngân sách mười mili giây, mang tính tất định, lặp lại liên tục mà không bao giờ bị tụt lại sau xung nhịp thời gian?*”

Ba Phân Kỳ Vật Lý: Các Ràng Buộc Cơ Học Của Âm Thanh

Từ thực tế duy nhất rằng âm thanh truyền đến tuần tự trong chế độ $batch = 1$, ba hệ quả vật lý tất yếu xuất hiện; mỗi ràng buộc trực tiếp định hình một yêu cầu phần cứng trong các chương tiếp theo.

1. Âm Thanh Không Có Ranh Giới Tự Nhiên (Mệnh Lệnh Trạng Thái Bộ Nhớ)

Một bức ảnh số bị giới hạn cứng nhắc bởi chiều cao H và chiều rộng W tính theo điểm ảnh hữu hạn. Một dạng sóng âm thanh dạng dòng không có cả hai: tiếng nói con người tiếp diễn liên tục vào tương lai, và bộ xử lý biên không thể quan sát toàn bộ tín hiệu trước khi bắt đầu công việc của mình.

Bởi vì bộ xử lý không thể nhìn trước tương lai, nó phải bắc cầu tính liên tục theo thời gian bằng cách lưu giữ ngữ cảnh quá khứ trong **trạng thái** (state)—một vùng bộ nhớ chuyên dụng, giới hạn chặt chẽ trên chip chứa những gì mà khung tiếp theo sẽ cần.

- *Câu nói phần cứng tới Chương 4:* Yêu cầu này thay đổi căn bản cách chúng ta định cỡ tài nguyên bán dẫn; khi triển khai các mô hình dạng dòng, câu hỏi “*Con chip sở hữu bao nhiêu đơn vị nhân tích lũy (MAC)?*” chỉ là thứ yếu so với câu hỏi kiến trúc sắc bén hơn nhiều: “*Cần bao nhiêu kilobit RAM khối (BRAM) hoặc UltraRAM (URAM) trên chip để duy trì trạng thái ngữ cảnh trái mà không bị đình trệ do truy xuất DRAM ngoài?*”

2. Quán Tính Sinh Học Chi Phối Vùng Gõi Khung (Mệnh Lệnh Bộ Đệm Vòng Trượt)

Vì sao các chuỗi xử lý âm học tiêu chuẩn luôn áp dụng bước nhảy khung 10 ms? Câu trả lời nằm ở cơ sinh học của con người.

Đường phát âm của con người—bao gồm lưỡi, môi, vòm mềm, hầu họng và xương hàm dưới—là một tập hợp các mô sinh học có khối lượng vật lý. Bởi vì các cơ quan phát âm này mang quán tính cơ học, chúng không thể thay đổi hình học vật lý của mình một cách tức thời. Do đó, tiếng nói con người duy trì tính chất **chuẩn dừng** (quasi-stationary, tức ổn định về mặt thống kê trong bao hình phổ) trong các khoảng thời gian ngắn từ 20 đến 30 ms.

Để chụp lại một ảnh phổ tĩnh đáng tin cậy về mặt thống kê, tăng tiền xử lý số phải quan sát một cửa sổ thời gian dài 25 ms (400 mẫu ở tần số lấy mẫu chuẩn $f_s = 16$ kHz). Tuy nhiên, để theo dõi chính xác các biến chuyển ngữ âm nhanh giữa các âm tắc, âm sát và nguyên âm, cửa sổ phân tích phải tịnh tiến theo các bước nhảy nhỏ $T_h = 10$ ms (160 mẫu).

Thực tế sinh học này tạo ra một hệ quả cơ học trực tiếp: **hai khung liên tiếp gối chồng sâu lên nhau**. Trong số 400 mẫu cấu thành khung phân tích hiện tại:

$$400 - 160 = 240 \text{ mẫu}$$

đã được thu nhận, đệm và phân tích trong khung liền trước.

► NHÌN THẤY VẬT LÝ

Vùng gổ chồng 240 mẫu giữa hai khung liên tiếp không phải là gánh nặng dư thừa; đó là một cơ hội kiến trúc mang tính cấu trúc. Trong phần mềm thông thường, việc trượt một mảng thường kích hoạt các thao tác sao chép bộ nhớ tốn kém (memmove). Trên FPGA, các khối RAM (BRAM) chuyên dụng trên chip cho phép các con trỏ địa chỉ đọc và ghi tịnh tiến tuần hoàn quanh một bộ đệm vòng cố định, cung cấp khung gổ chồng cho chuỗi DSP mà không tốn công sao chép dữ liệu và không gây tắc nghẽn bus (được hình thức hóa ở Mục 1.2 và kiểm chứng trên silicon ở Chương 4 và 9).

3. Đồng Hồ Của Tự Nhiên Không Thể Thương Lượng (Khủng Hoảng Mất Mẫu)

Màng rung cơ học của micro không bao giờ ngừng dao động chỉ vì một nhân CPU ở hạ nguồn đang bận phục vụ ngắt hệ điều hành hay gặp hiện tượng trượt bộ nhớ đệm (cache miss).

Trong thị giác máy tính, một hàng đợi xử lý bị nghẽn chỉ đơn thuần làm chậm thời điểm hoàn thành một khung ảnh tĩnh thêm vài mili giây; các điểm ảnh vẫn nằm nguyên vẹn trong bộ nhớ. Trong âm thanh dạng dòng, một hàng đợi không được phục vụ kịp thời sẽ khiến bộ đệm đầu vào bị tràn, dẫn đến hiện tượng **mất mẫu** (dropped samples). Bởi vì dạng sóng âm học là một chuỗi thời gian liên tục và không thể đảo ngược, một mẫu âm thanh bị rơi sẽ vĩnh viễn biến mất; nó không bao giờ có thể lấy lại hay tính toán bù. Trên một đường ống giọng nói biên, ngân sách khung 10 ms không phải là một mục tiêu tối ưu hóa tùy chọn; đó là một thời hạn vật lý bất khả thương lượng.

Định Nghĩa Lại “Tốc Độ”: Thông Lượng so với Độ Trễ Khung Tắt Định

Ba ràng buộc cơ học này thúc đẩy một sự chuyển dịch sâu sắc trong cách một kỹ sư định nghĩa tốc độ tính toán.

Một bộ tăng tốc thị giác máy tính được đánh giá bằng **thông lượng**—tổng số lượng ảnh được xử lý mỗi giây dưới tải gom lô cao. Trái lại, một bộ tăng tốc giọng nói biên thời gian thực được đánh giá trước hết và trên hết bởi **độ trễ thực thi tắt định**: liệu cỗ máy xử lý có bảo đảm rằng mỗi khung đơn lẻ đều hoàn thành toàn bộ chuỗi trích xuất và phân loại nằm gọn trong hạn định vật lý 10 ms, từ chu kỳ này sang chu kỳ khác với độ biến thiên bằng không hay không. Chỉ sau khi giao ước thời gian này được đảm bảo, thiết kế mới tối ưu hóa cho **hiệu quả năng lượng trên từng khung** (mJ/khung).

Lý do chính khiến GPU truyền thống không phải là cỗ máy tự nhiên cho giọng nói biên thời gian thực không nằm ở sự thiếu hụt sức mạnh số học thô. Thay vào đó, diện tích silicon của nó được tối ưu hóa cho một chỉ số—thông lượng song song khối lớn qua các lô rộng—mà một hệ thống dạng dòng tương tác (*batch* = 1) bị cấm sử dụng về mặt vật lý. Chương 3 phát triển lập luận này với các phép đo lường về những gì xảy ra với một bộ xử lý Đơn lệnh Nhiều luồng (SIMT) khi chỉ có duy nhất một khung để xử lý.

Thế Lưỡng Nan Chưa Có Lời Giải: Khủng Hoảng Thu Nhận Dạng Dòng Nếu âm thanh truyền đến như một dòng mẫu áp suất không khí liên tục vô tận không thể gom lô mà không phải trả giá bằng độ trễ chí mạng, thì làm thế nào một bộ xử lý biên có thể biến một lần sóng liên tục vô hạn thành các gói toán học hữu hạn mà không làm mất mát thông tin hoặc tạo ra những biến dạng ranh giới nghiêm trọng?

Thế lưỡng nan vật lý này dẫn chúng ta trực tiếp tới cỗ máy toán học của chuỗi tiền xử lý dạng dòng trong Mục 1.2.

1.2 Chuỗi Tiền Xử Lý Âm Thanh Dạng Dòng

► MỤC TIÊU HỌC TẬP

Thay vì xem tầng tiền xử lý (frontend) như một công thức lập trình thuần túy (khung $\rightarrow$ FFT $\rightarrow$ Mel $\rightarrow$ log), mục này lần theo từng gói dữ liệu vật lý vượt qua các ranh giới tính toán. Chúng ta sẽ chứng minh vì sao đặc tính âm thanh biên bắt buộc phải xử lý dạng dòng với kích thước lô bằng một ($B = 1$), bề gây ba từ huyết ngộ nhận khi đưa tiền xử lý lên phần cứng, và giải mã lý do kiến trúc bộ nhớ cùng số học con trỏ trên chip phải khớp chính xác với kích thước các tensor âm học.

Ở Mục 1.1, chúng ta đã xác lập một nguyên lý vật lý: âm thanh không cho phép gom lô ($B > 1 \implies$ độ trễ). Dù vậy, bộ xử lý tín hiệu số và mô hình âm học nơ-ron không thể nuốt trọn một lần sóng tương tự vô tận. Để trích xuất biểu diễn ngôn ngữ từ áp suất không khí biến thiên liên tục, chúng ta phải xây dựng một đường truyền dữ liệu (datapath) phần cứng – phần mềm có khả năng cắt lát, điều hòa và biến đổi dòng âm thanh với tính tất định thời gian tuyệt đối.

Mục này theo chân dòng dữ liệu qua sáu phép biến đổi tiêu chuẩn được triển khai trong mã nguồn tham chiếu `chapter01/exp_01_streaming_audio_pipeline.py`: dạng sóng thô, bộ đệm vòng trượt (sliding ring buffer), cửa sổ thuôn nhọn (tapering window), biến đổi Fourier thời gian ngắn (Short-Time Fourier Transform – STFT), ngân hàng bộ lọc Mel (Mel filterbank), và nén logarit (logarithmic compression). Sáu tầng xử lý này không phải là một giáo trình phần mềm tùy tiện. Mỗi khối sinh ra bởi vì tầng vật lý liền trước để lại một thể lượng nan cơ học mà nếu không giải quyết thì phép tính số học tiếp theo không thể vận hành:

- Áp suất không khí là đại lượng liên tục, trong khi phần cứng số chỉ lưu trữ các con số rời rạc; sóng âm vật lý do đó phải được **lấy mẫu** tại các khoảng xung nhịp đều đặn.
- Âm thanh dòng không có điểm kết thúc, trong khi giải tích tần số đòi hỏi một khối số hữu hạn đứng yên; hệ thống do đó phải duy trì một **bộ đệm** kích thước cố định, tịnh tiến dần theo từng bước nhảy rời rạc.
- Việc cắt ngang một lần sóng đang dao động tạo ra các bước nhảy đột ngột tại ranh giới khung mà bộ phân tích Fourier sẽ nhận diện nhầm thành các họa âm cao tần giả tạo; mỗi khung do đó phải được **áp cửa sổ** (thuôn dần về 0) trước khi biến đổi.
- Thao tác thuôn mép triệt tiêu năng lượng tại biên khung – nơi vẫn chứa thông tin âm học; hai khung liên tiếp do đó phải **gối chồng sâu**, kích hoạt một chu trình phân tích phổ sau mỗi bước nhảy thay vì sau mỗi chiều dài cửa sổ.
- Khung tín hiệu sau khi áp cửa sổ vẫn nằm trong miền thời gian, che giấu các tần số cộng hưởng; phép biến đổi **STFT** so khớp khung với N tần số đồ ứng viên để tạo ra biểu diễn phổ công suất.
- 257 bin tần số tuyến tính thu được có độ dư thừa quá cao cho mô hình âm học hạ nguồn và phân bố theo thang Hertz tuyến tính vốn không phản ánh thính giác người; chúng được gom vào 80 dải **ngân hàng bộ lọc Mel** phi tuyến.
- Năng lượng giữa các dải phổ dao động cách nhau hàng triệu lần, khiến phép cộng trong mạng nơ-ron bị dải âm lớn nhất chi phối áp đảo; từng giá trị năng lượng do đó được nén bằng cách lấy **logarit**.

Bước 1: Dạng Sóng và Lấy Mẫu Nyquist

Âm thanh được ghi lại dưới dạng chuỗi thời gian rời rạc đo sự biến thiên của áp suất khí quyển. Khoảng cách thời gian giữa hai lần đo liên tiếp do **tần số lấy mẫu** (f_s – sampling frequency) quy định, biểu thị số lượng mẫu đo được thu thập trong một giây.

Chuỗi tiền xử lý âm thanh biên tiêu chuẩn vận hành ở $f_s = 16$ kHz. Cứ mỗi chu kỳ lấy mẫu $T_s = 62,5 \mu s$, đúng một mẫu mới xuất hiện từ bộ chuyển đổi tương tự – số (Analog-to-Digital Converter – ADC) của micro, và một cửa sổ phân tích 25 ms sẽ tích lũy đủ 400 mẫu. Ràng buộc tham số này bắt nguồn trực tiếp từ cơ sinh học phát âm của con người:

- Dây thanh đới dao động ở tần số cơ bản (F_0) từ 85 Hz (giọng nam trầm) đến 255 Hz (giọng nữ cao).
- Các khoang cộng hưởng của đường dẫn âm (hầu họng, khoang miệng, khoang mũi) tạo ra các đỉnh cộng hưởng formant (F_1, F_2, F_3) định hình nguyên âm, trải rộng từ 300 Hz đến 3.500 Hz.
- Thành phần tần số cao nhất trong tiếng nói người xuất hiện ở các phụ âm xát và phụ âm bật vô thanh (như /s/ và /sh/), triệt tiêu nhanh chóng ở dải trên 8 kHz.

Theo định lý lấy mẫu Nyquist-Shannon (Nyquist-Shannon sampling theorem), quá trình khôi phục hoàn hảo một tín hiệu giới hạn băng thông đòi hỏi tần số lấy mẫu phải lớn hơn ít nhất hai lần tần số cao nhất của nó ($f_s \geq 2B$). Tần số 16 kHz thiết lập ranh giới Nyquist tại 8 kHz, bao trọn toàn bộ phổ ngữ âm của con người đồng thời loại bỏ tiếng rít siêu âm từ môi trường. Việc nâng tần số lấy mẫu lên chuẩn CD (44,1 kHz) hay chuẩn phòng thu (48 kHz) làm tăng gấp ba kích thước bộ đệm trên chip, băng thông bus và khối lượng tính toán mà không mang lại thêm bất kỳ thông tin ngữ âm có nghĩa nào cho mô hình nhận dạng. Ràng buộc 16 kHz là quy chuẩn cố định bắt buộc từ các bộ dữ liệu huấn luyện thực tế (như Speech Commands hay LibriSpeech), không phải là một lựa chọn thẩm mỹ tùy tiện.


Bước 2: Bộ Đệm Vòng Trượt

Tầng tiền xử lý quan sát một cửa sổ dài $L = 400$ mẫu sau mỗi bước nhảy, tiến dần trên dòng âm thanh đầu vào theo từng bước $H = 160$ mẫu ($T_h = 10$ ms).

Để hiểu cách phân cứng giải quyết vùng gói đầu này, hãy xem xét hai giả thuyết triển khai đối lập:

- **Giả thuyết A (Dịch chuyển bộ nhớ ngay thơ trong phần mềm):** Bộ xử lý xem bộ đệm khung như một mảng tuyến tính liên tục. Khi 160 mẫu mới xuất hiện, phần mềm thực thi lệnh dịch chuyển bộ nhớ (memmove), sao chép 240 mẫu gần nhất lùi về đầu mảng trước khi ghi nối tiếp 160 mẫu mới vào phần đuôi.
- **Giả thuyết B (Bộ đệm con trỏ vòng trong phần cứng):** Địa chỉ ô nhớ nằm cố định trong bộ nhớ RAM khối (Block RAM – BRAM) trên chip. Thay vì dịch chuyển các phần tử dữ liệu, kiến trúc cập nhật hai thanh ghi con trỏ địa chỉ tuần hoàn tăng theo modulo 400.

Lời giải chứng minh tính ưu việt của phần cứng chuyên dụng trước bus bộ nhớ đa dụng: ở Giả thuyết A, bộ xử lý phải trả một khoản thuế truyền thông định kỳ sau mỗi khung gồm 240 thao tác đọc và 240 thao tác ghi bộ nhớ. Trên một dòng âm thanh vô tận, sự di chuyển dữ liệu thừa thãi này liên tục thiêu đốt băng thông bus và năng lượng truy xuất bộ nhớ. Ở Giả thuyết B, các mẫu vật lý một khi đã ghi vào Block RAM sẽ không bao giờ dịch chuyển vị trí. Con trỏ ghi tiến thêm 160 địa chỉ để ghi đè lên dữ liệu cũ nhất, trong khi con trỏ đọc phát dòng 400 mẫu liên tục vào đường truyền tính toán bắt đầu từ ranh giới vừa cập nhật.



Hình 1.2a: Sự đối lập cơ học giữa thao tác dịch bộ nhớ trong phần mềm (a) và cơ chế bộ đệm vòng phần cứng (b) cho khung 400 mẫu với bước nhảy 160 mẫu ($T_h = 10$ ms). Trong khi phần mềm phải liên tục đọc và ghi 240 mẫu qua bus sau mỗi bước nhảy, phần cứng giữ cố định dữ liệu trong Block RAM và chỉ dịch chuyển hai thanh ghi con trỏ theo modulo 400, triệt tiêu hoàn toàn chi phí dịch chuyển mẫu.

★ PHÁT HIỆN THEN CHỐT

Trên kiến trúc không gian FPGA, chi phí năng lượng và chu kỳ xung nhịp để dịch chuyển dữ liệu khi gói khung giảm về 0:

Năng lượng dịch chuyển dữ liệu $\rightarrow 0$

Trạng thái âm học giữa các khung không nằm trong các vòng lặp sao chép phần mềm. Trạng thái này lưu giữ hoàn toàn trong các bit địa chỉ của hai thanh ghi con trỏ BRAM tuần hoàn. Đây chính là khối lưu giữ trạng thái bền vững đầu tiên trong chuỗi xử lý giọng nói dạng dòng.

Bước 3: Áp Cửa Sổ và Sự Gián Đoạn Ranh Giới

Khung phân tích 400 mẫu đại diện cho một lát cắt chữ nhật hữu hạn trích xuất từ sóng âm tương tự liên tục. Một nhát cắt chữ nhật hoạt động như một hàm bước nhảy sắc nhọn: tín hiệu bắt đầu tức thì ở mẫu 0 và ngắt đột ngột ở mẫu 399.

Đối với bộ phân tích Fourier, bước nhảy thẳng đứng không thể phân biệt được với các họa âm cao tần vốn không hề tồn tại trong môi trường âm thanh thực. Nếu biến đổi trực tiếp, vách đứng ranh giới gây ra hiện tượng **rò rỉ phổ** (spectral leakage) nghiêm trọng, làm nhòe năng lượng sang các bin tần số kế cận.

Để ngăn ngừa biến dạng này, 400 mẫu lưu trong bộ đệm vòng được nhân từng phần tử với cửa sổ **Hamming** đối xứng $w[n]$:

$$x_w[n] = x[n] \cdot w[n], \quad 0 \leq n < 400$$

Cửa sổ Hamming thuôn mượt về gần 0 ở cả hai mép ranh giới, đảm bảo dạng sóng tiến vào và rời khỏi khung phân tích mà không tạo ra các bước nhảy gây khúc.

► NHÌN THẤY VẬT LÝ

Cửa sổ thuôn nhọn là khoản thuế ranh giới phải trả để bộ phân tích Fourier không vấp phải vách đứng nhân tạo. Việc ép các mẫu ranh giới về gần 0 triệt tiêu họa âm cao tần giả tạo nhưng làm suy hao năng lượng thật ở mép khung. Sự suy hao này gây ra hiện tượng nhòe rộng phổ, khiến hai khung kế tiếp bắt buộc phải gói chồng sâu 240 mẫu để mọi biến cố âm học đều có cơ hội được phân tích tại vùng đỉnh cửa sổ.

Bước 4: Biến Đổi Fourier Thời Gian Ngắn (STFT)

Việc tính toán biến đổi Fourier rời rạc (Discrete Fourier Transform – DFT) trên các khung đã áp cửa sổ liên tiếp theo thời gian tạo nên biến đổi Fourier thời gian ngắn (STFT).

Để tính DFT với hiệu năng tối ưu, 400 mẫu sau khi áp cửa sổ được mở rộng lên 512 mẫu bằng cách chèn thêm 112 giá trị 0 (**đệm số không** – zero-padding). Việc đệm kích thước lên lũy thừa của 2 ($N_{\text{fft}} = 512$) cho phép đường truyền tận dụng cấu trúc biến đổi Fourier nhanh (Fast Fourier Transform – FFT) cơ số 2.

Vì tín hiệu âm thanh đầu vào hoàn toàn là các giá trị thực, phổ phức thu được mang tính đối xứng liên hợp: nửa trên của các bin tần số là bản sao phản chiếu của nửa dưới. Đường ống xử lý loại bỏ phần tần số âm dư thừa, chỉ giữ lại $N_{\text{fft}}/2 + 1 = 257$ bin tần số dương thực thụ. Phổ công suất (power spectrum) được tạo ra bằng cách lấy bình phương độ lớn của các giá trị phức này, mang lại 257 giá trị năng lượng thực mô tả mật độ phân bố công suất trên toàn dải tần.

Bước 5: Ngân Hàng Bộ Lọc Mel

257 bin phổ công suất phân bố đều dải tần số từ 0 đến 8 kHz.

Tuy nhiên, thính giác con người không cảm nhận chênh lệch tần số theo thang tuyến tính. Ốc tai người phân giải các âm trầm với độ chính xác cao nhưng lại gom các âm bổng vào những dải cảm nhận rộng. Hơn nữa, việc cấp trực tiếp 257 giá trị phổ vào một mạng nơ-ron nhỏ sẽ làm bùng nổ số lượng tham số không cần thiết.

Đường truyền nén 257 bin tuyến tính thành $M = 80$ dải **ngân hàng bộ lọc Mel**. Mỗi bộ lọc Mel là một hàm trọng số hình tam giác phủ lên một cụm bin FFT kế cận. Các bộ lọc được bố trí dày đặc ở dải tần thấp và dần rộng dần về phía dải tần cao. Năng lượng đầu ra của từng dải Mel là tổng có trọng số của các bin phổ công suất nằm dưới tam giác lọc đó, thực hiện qua phép nhân với ma trận trọng số thưa kích thước 80×257 .

Bước 6: Nén Logarit

Năng lượng âm học trên 80 dải Mel có thể chênh lệch nhau hàng triệu lần giữa một tiếng thì thầm khẽ và một tiếng bật phụ âm vang dội. Nếu đưa thẳng các giá trị năng lượng thô vào mô hình âm học nơ-ron, biên độ quá lớn sẽ làm bão hòa các hàm kích hoạt và chỉ phối hoàn toàn quá trình cập nhật trọng số.


Thính giác con người cảm nhận độ to theo tỷ lệ cường độ âm thay vì chênh lệch số học tuyến tính. Bước tiền xử lý cuối cùng nén logarit năng lượng của từng dải Mel. Ngưỡng chặn dưới 10^{-6} đóng vai trò số học sống còn: trong các khoảng lặng hoàn toàn khi năng lượng dải tiến sát 0, ngưỡng chặn ngăn toán tử logarit rơi vào âm vô cùng ($-\infty$), bảo đảm tính ổn định số học trên cả đường ống phân cứng dấu phẩy động lẫn dấu phẩy tĩnh.

Kích Thước Tensor và Dung Lượng Bộ Nhớ

Trong kiến trúc silicon, kích thước tensor không phải là các con số trừu tượng trên phần mềm; chúng quy định trực tiếp độ rộng bit của thanh ghi, độ sâu của Block RAM và băng thông đường truyền bộ nhớ. Toàn bộ tiến trình biến đổi dữ liệu trên một khung 10 ms được tổng hợp trong Bảng 1:

Bảng 1: Kích thước tensor âm thanh dòng và dung lượng bộ nhớ FP32 trên mỗi khung 10 ms.

Tầng Xử Lý	Dữ Liệu Sinh Ra Mỗi Khung	Dung Lượng FP32 (Float 32-bit)
Dạng sóng đầu vào	160 mẫu mới	640 B nạp mỗi 10 ms
Bộ đệm vòng trượt	400 mẫu thường trú	1.600 B, trạng thái duy trì trên chip
Khung sau áp cửa sổ	400 mẫu qua cửa sổ	1.600 B (bộ đệm × cửa sổ Hamming)
Bộ đệm đầu vào FFT	512 mẫu	2.048 B (400 mẫu thực + 112 mẫu số 0)
Phổ công suất	257 bin phổ	1.028 B (257 giá trị năng lượng thực)
Dải ngân hàng bộ lọc Mel	80 giá trị bộ lọc	320 B (nhân ma trận 80×257)
Khung đặc trưng Log-Mel	80 đặc trưng log năng lượng	320 B (đầu vào trực tiếp cho mô hình âm học)



Hình 1.2b: Kích thước tensor và dung lượng bộ nhớ dọc theo đường truyền dữ liệu âm thanh dòng cho một khung phân tích 10 ms. Dữ liệu nở rộng từ 160 mẫu (640 B) lên 512 điểm đệm không (2.048 B) để biến đổi phổ, sau đó nén gọn về 80 giá trị log năng lượng (320 B) cấp cho mô hình âm học, khẳng định cấu hình bộ đệm và độ rộng bus phần cứng do chính hình dạng tensor DSP quy định.

Bẻ Gãy Ngộ Nhận: Ba Tử Huyệt Trong Tiền Xử Lý Giọng Nói Dạng Dòng

Ba cam bẫy nhận thức sau đây thường xuyên gây sai lầm cho các kỹ sư khi chuyển từ học máy ngoại tuyến (offline) hoặc lập trình ứng dụng nói chung sang thiết kế trên phần cứng FPGA:

△ BẺ GÃY NGỘ NHẬN: Bẫy A — Tần số lấy mẫu càng cao (48 kHz) thì AI càng chính xác

Căn nguyên: Trục giác âm thanh trung thực cao (Hi-Fi) đánh đồng tần số lấy mẫu cao (48 kHz hoặc 96 kHz) với chất âm trong trẻo, khiến kỹ sư ngộ nhận rằng tần số cao hơn sẽ giúp mô hình âm học nhận dạng chính xác hơn.

Thực tế khoa học: Các đỉnh cộng hưởng formant tiếng người (F_1, F_2, F_3) chỉ nằm trong khoảng từ 300 Hz đến 3.500 Hz, trong khi các phụ âm sát vô thanh triệt tiêu trước 8 kHz. Việc tăng f_s lên 48 kHz chỉ thu thêm tiếng xì siêu âm của môi trường trong khi thổi phồng dung lượng BRAM trên chip, băng thông bus và độ phức tạp tính toán FFT lên gấp ba lần mà không mang lại bất kỳ lợi thế ngữ âm nào cho mô hình nhận dạng.

△ BẺ GÃY NGỘ NHẬN: Bẫy B — Bộ đệm khung trượt chỉ là thao tác sao chép bộ nhớ trong phần mềm

Căn nguyên: Trong mã nguồn Python hoặc C tiêu chuẩn, bước dịch khung phân tích được thực thi bằng hàm dịch chuyển bộ nhớ (memmove), tiêu tốn 240 chu kỳ đọc và 240 chu kỳ ghi sau mỗi bước nhảy.

Thực tế khoa học: Trên kiến trúc phần cứng không gian FPGA, bộ đệm vòng tiêu tốn đúng 0 chu kỳ xung nhịp sao chép. Bằng cách hiện thực hai thanh ghi đếm chạy vòng quanh Block RAM trên chip, các mẫu âm thanh nằm yên tại chỗ trong khi địa chỉ cuộn theo modulo 400. Chi phí truyền dữ liệu tuần tự $\mathcal{O}(L - H)$ biến mất hoàn toàn.

△ BẺ GÃY NGỘ NHẬN: Bẫy C — Cắt khung bằng cửa sổ chữ nhật giữ nguyên vẹn mẫu âm thanh gốc

Căn nguyên: Phép cắt phẳng chữ nhật giữ nguyên giá trị số của mẫu âm thanh mà không nhân với bất kỳ hệ số suy hao nào, tạo cảm giác tín hiệu đạt độ trung thực tuyệt đối.

Thực tế khoa học: Bước nhảy đột ngột tại hai ranh giới khung tạo ra các sóng hài cao tần giả mạo vốn không hề tồn tại trong phòng thu. Đối với biến đổi Fourier, mép cắt sắc nhọn giống như các xung tần số vô hạn gây hiện tượng rò rỉ phổ nghiêm trọng sang các bin lân cận. Việc áp dụng cửa sổ trơn mượt (Hamming) là bắt buộc về mặt vật lý để triệt tiêu nhiễu ranh giới.

Thế Lưỡng Nan Chưa Giải Quyết: Độ Nhòe Tần Số

Qua sáu tầng xử lý của đường truyền này, chúng ta đã điều hòa sóng áp suất không khí thô thành các vector đặc trưng 80 chiều ổn định, phát ra đều đặn mỗi 10 ms.

Dù vậy, phép chuyển đổi này làm lộ rõ một mâu thuẫn vật lý cốt lõi: khi bóp ngắn cửa sổ phân tích xuống 25 ms để bảo toàn tính dừng thời gian, khả năng phân tách hai tần số cộng hưởng nằm sát nhau sẽ bị ảnh hưởng ra sao? Độ rộng hữu hạn của từng bin phân tích phổ làm nhòe các họa âm kế cận như thế nào, và ngân hàng bộ lọc Mel cân bằng sự đánh đổi giữa độ phân giải thời gian và độ phân giải tần số theo cơ chế nào để cách ly các formant?

Thế lưỡng nan toán học này dẫn dắt chúng ta trực tiếp vào phần dẫn xuất giải tích chi tiết của STFT và ngân hàng bộ lọc Mel trong Mục 1.3.